學號: B05901003 系級:電機二姓名:徐敏倩

1. 請比較你實作的generative model、logistic regression 的準確率,何者較佳?在資料處理的部份,皆是使用已經分好的X\_train, Y\_train(且已特徵標準化),Logistic Regression的準確率皆較 Generative Model來的高。下表中,Generative Model是利用 Gaussian distribution的假設實作;Logistic Regression的部分,learning rate為0.01,gradient descent 的部分用adagrad,訓練 100000個 epoch。

	Training Accuracy	Testing Accuracy
Logistic Regression	0.853291	0.852645
Generative Model	0.842296	0.843860

- 2. 請說明你實作的best model,其訓練方式和準確率為何? 我的best model是用fully connected forward network,input data是用已經分好的X\_train, Y\_train,並已做特徵標準化,且切割出前三分之二作為 training set、後三分之一作為 validation set。Network中有三個 hidden layer,第一、二、三層中分別有1024, 512, 128 個 neurons,而每一層都有用activation function, sigmoid,loss function為 'binary\_crossentropy',optimizer為'adam',且在選擇model時,是選擇在 validation set 準確率最高的model。
- 3. 請實作輸入特徵標準化(feature normalization)並討論其對於你的模型準確率的影響由下表可知(以 Logistic Regression為例),當資料未經過特徵標準化的處理時,準確率不管是在 training set還是在 testing set上都較經過特徵標準化的差。除了準確率之外,在未做特徵標準化時,learning rate需要在0.0001左右,才有辦法收斂,否則便會在 training accuracy為0.76,0.24之間跳,而根本不會上升;而經過特徵標準化後的資料,learning rate為0.1時,就已經可以收斂了。

		Training Accuracy	Testing Accuracy
Logistic Regression	Original	0.804275	0.806825
	Normalization	0.853291	0.852645

未經特徵標準化: learning rate為0.0001、gradient descent部分用adagrad、epoch為10000經過特徵標準化: learning rate為0.01、gradient descent部分用adagrad、epoch為10000

4. 請實作logistic regression 的正規化(regularization),並討論其對於你的模型準確率的影響。

λ	Training Accuracy	Testing Accuracy
0.1	0.7855	0.7858
1	0.7643	0.7691
10	0.7636	0.7681
100	0.7632	0.7677

從上表中可以得知,在  $\lambda$  = 0.1 的情況下,準確率較其他幾個來的稍微高一點;但在  $\lambda$  = 1, 10, 100時,  $\lambda$  的影響並不大,但還是可以發現,不論是 training accuracy 還是 testing accuracy,其實都會因  $\lambda$  變大而減少。

5. 請討論你認為哪個attribute 對結果影響最大?

我認為最重要的是workclass,當我去掉workclass這個attribute,以其他attribute作為訓練資料時,準確率降到80.87%左右;其次則為marital\_status,當我去掉此attribute,以其他attribute作為訓練資料時,準確率降到81.75%左右。而對於其他的attribute重複相同的步驟,準確率都還是落在83%到85%之間。因此,workclass、marital\_status這兩個 attribute對結果的影響最大。